先進製程數位晶片設計實作（一）
Homework 3

李品翰
M11507401

研究動機與模型

浮點參數占用較多儲存空間。以定點量化降低模型大小，同時維持分類準確率，作為後續硬體實作的參考。

運算階段	設定	輸出大小
輸入	$32 \times 32 \times 3$，扣除平均圖片	$32 \times 32 \times 3$
conv1、ReLU、pooling	3×3，64 通道；2×2 pooling	$16 \times 16 \times 64$
conv2、ReLU、pooling	3×3，128 通道；2×2 pooling	$8 \times 8 \times 128$
conv3、ReLU、pooling	3×3，256 通道；2×2 pooling	$4 \times 4 \times 256$
fc1	$4096 \to 512$	512×1
fc2、softmax	$512 \to 10$	10×1 機率

使用老師提供的 HW2 模型與 1,000 張 CIFAR-10 測試圖片；推論略過 dropout。
只量化既有參數，不重新訓練、不剪枝。目標：準確率 $> 80\%$、平均位元數 ≤ 16。

儲存空間占比：集中壓縮主要三層

設定	參數	數量	占比
`WL_W(1)`	conv1 權重	1,728	0.070%
`WL_W(2)`	conv2 權重	73,728	2.977%
`WL_W(3)`	conv3 權重	294,912	11.908%
`WL_W(4)`	fc1 權重	2,097,152	**84.676%**
`WL_W(5)`	fc2 權重	5,120	0.207%
`WL_B`	五層 bias	970	0.039%
`WL_M`	平均圖片 $(32 \times 32 \times 3)$	3,072	0.124%
合計		**2,476,682**	**100%**

相同位元數下，`WL_W(2:4)` 占 **99.560%**；其餘僅占 **0.440%**。
因此將其餘參數固定為 16 bits，優先降低 conv2、conv3 與 fc1 的位元數。

方法：定點量化

WL 為總位元數，**FL** 決定刻度 2^{-FL}。對原參數 x 四捨五入後做飽和截限，再還原為運算用數值：

$$q = \min\big(\max\big(\mathrm{round}(x2^{FL}), -2^{WL-1}\big), 2^{WL-1}-1\big), \qquad \hat{x} = q2^{-FL}.$$

超出範圍時取上下限；恰為半整數時向遠離零方向取整。

- 權重採 per-channel：每個輸出通道獨立選 FL，同層共用 WL。
- bias 與平均圖片，各組參數共用一個 FL。
- 固定 WL 後，以 `choose_fl` 選擇量化誤差最小的 FL。
- activation 使用 32 bits，在輸入扣均值後、三個 ReLU 後與兩個 FC 後量化。

以平均平方誤差（MSE）衡量整組參數的量化誤差：

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(x_i - \hat{x}_i)^2.$$

N 是這組參數的數量；MSE 越小，量化後越接近原始參數。

方法：choose_fl 搜尋流程

1. **起點：**根據 WL 與 $\max_i |x_i|$ 估算 FL，若四捨五入後溢位，就降低 FL，直到全部數值放得下。
2. **逐一搜尋：**計算目前 FL 的 MSE，記錄目前最佳 MSE 與對應 FL，接著將 FL 加 1。
3. **停止：**當目前 FL 的截限誤差 $E_{\text{clip}} \geq \text{MSE}_{\text{best}}$，停止搜尋並回傳最佳 FL。

截限誤差：只計算超出範圍的數值，與上下限之間的距離。令可表示範圍為 $[l, u]$：

$$E_{\text{clip}} = \frac{1}{N} \sum_i \left[\max(l - x_i, 0)^2 + \max(x_i - u, 0)^2 \right].$$

FL 越大，範圍越小，截限誤差不會下降。當它已達到最佳 MSE，後面的 FL 就不可能更好。

程式以總平方誤差比較；兩側同除以 N 後，即為此處的 MSE，停止條件相同。

主要實驗：16 bits 降至混合 2 ／ 3 bits

每組測試 1,000 張圖片，開啟 per-channel；conv1、fc2 權重及全部 bias、Mean 固定為 16 bits，僅調整 conv2、conv3、fc1。

主要三層設定	正確張數	準確率	平均 bits	模型縮減
原始 FP32	845	84.5%	32.000000	0.000%
$(16, 16, 16)$	845	84.5%	16.000000	50.000%
$(8, 8, 8)$	846	84.6%	8.035176	74.890%
$(4, 4, 4)$	828	82.8%	4.052764	87.335%
$(3, 3, 3)$	824	82.4%	3.057161	90.446%
$(3, 3, 2)$	**823**	**82.3%**	**2.210402**	**93.092%**

其餘參數固定 16 bits；平均 bits 依各組參數數量加權：

$$\overline{WL} = \frac{\sum_t N_t WL_t}{\sum_t N_t}, \qquad \text{模型縮減} = \left(1 - \frac{\overline{WL}}{32}\right) \times 100\%.$$

混合位元比較：保留 conv2、conv3 的精度

$(\text{conv2}, \text{conv3}, \text{fc1})$	準確率	平均 bits	是否 $> 80\%$
$(2, 2, 3)$	73.9%	2.908317	否
$(2, 3, 2)$	76.6%	2.180634	否
$(3, 2, 2)$	75.2%	2.091327	否
$(3, 3, 2)$	**82.3%**	**2.210402**	**是**

- 測試配置中，兩個主要卷積層皆保留 3 bits 才達到準確率要求。
- 選擇 $(3, 3, 2)$：相較 $(3, 3, 3)$ 僅少答對 1 張，平均位元數由 3.057161 降為 2.210402。

其餘參數固定 16 bits。

最終結果：達到目標，停止優化

最終配置： `WL_W=[16 3 3 2 16]`，`WL_B=WL_M=16`，`WL_A=32`，per-channel 開啟。

指標	原始模型	最終定點模型
準確率	84.5%	**82.3%**
平均 bits ／參數	32	**2.210402**
參數儲存大小	9,906,728 bytes	684,308 bytes
模型剩餘比例	100%	6.908%

準確率下降 **2.2 個百分點**，模型縮減 **93.092%**，壓縮倍率為 **14.477 倍**。

準確率 $> 80\%$ 且平均 bits ≤ 2.5，已達程式評分公式的滿分條件；因此停止進一步優化。